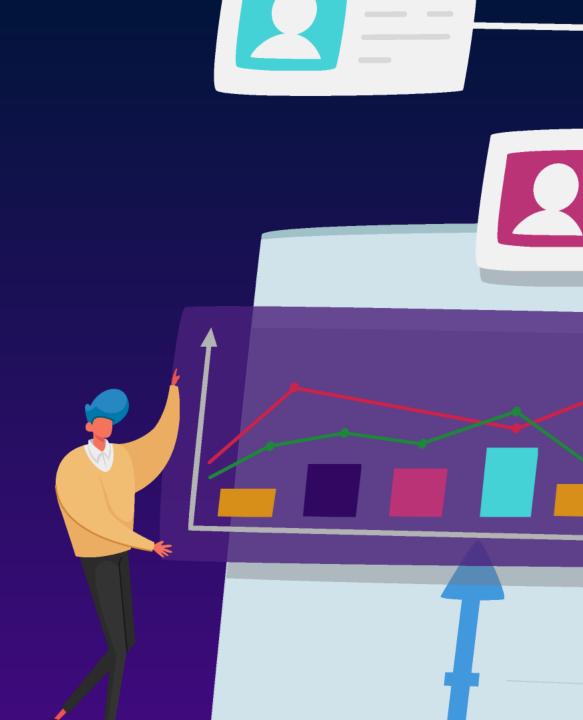




### Introduction

Face à un marché en constante évolution, Olist souhaite transformer sa stratégie Data pour mieux comprendre et servir sa clientèle.

Pour cela nous devons développer une segmentation client dynamique, intuitive et évolutive.



# Table des matières

1 Feature Engineering

Exploration des Données

3 Nettoyage des Données

4 Modélisation

5 Maintenance du Modèle

# Comprendre Olist et Sa Base de Données



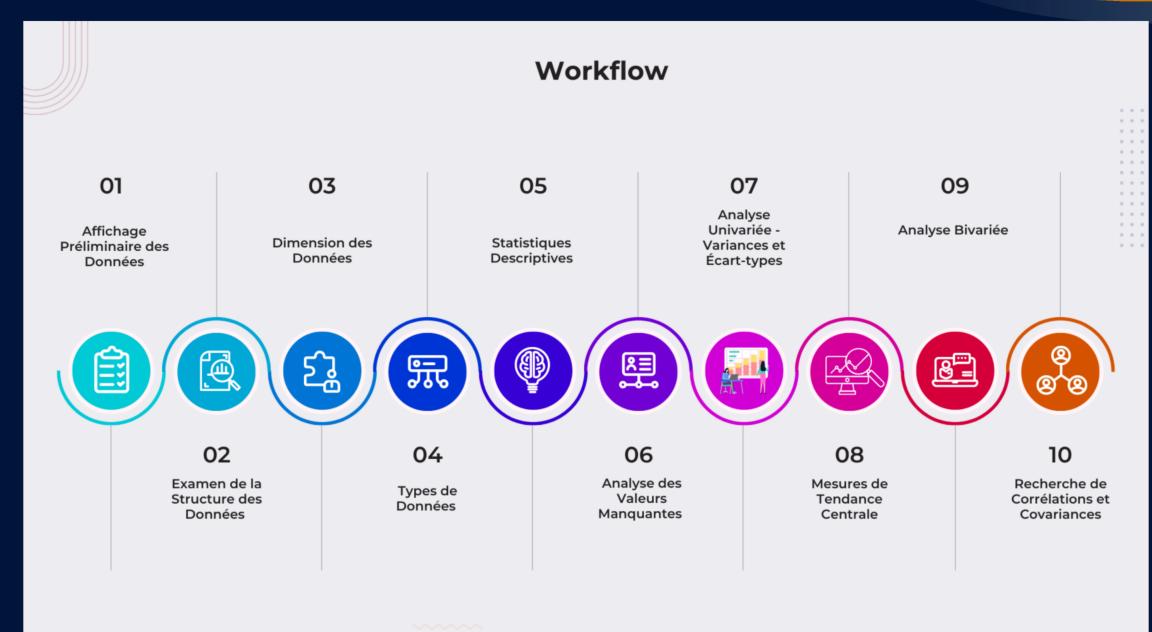




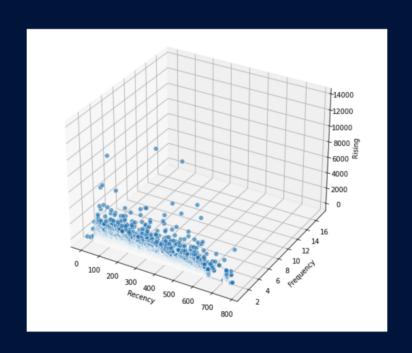
# **Feature Engineering**

<b>\$</b>	customer_unique_id \$	Importance \$	Recency \$	Frequency \$	Rising \$	Review_average \$
0	0000366f3b9a7992bf8c76cfdf3221e2	False	2018-05-10 10:56:27	1	141.90	5.0
1	0000b849f77a49e4a4ce2b2a4ca5be3f	False	2018-05-07 11:11:27	1	27.19	4.0
2	0000f46a3911fa3c0805444483337064	False	2017-03-10 21:05:03	1	86.22	3.0
3	0000f6ccb0745a6a4b88665a16c9f078	False	2017-10-12 20:29:41	1	43.62	4.0
4	0004aac84e0df4da2b147fca70cf8255	False	2017-11-14 19:45:42	1	196.89	5.0

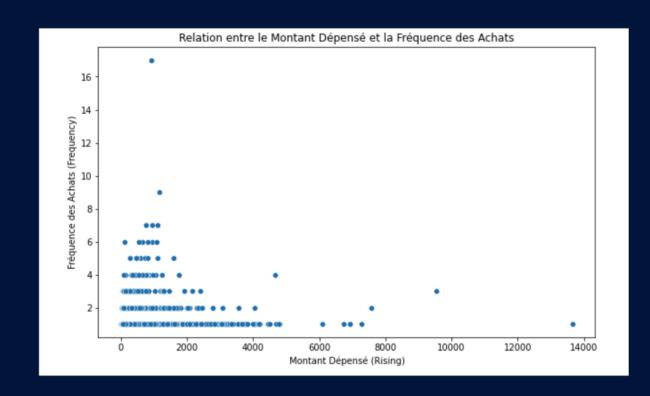
# **Exploration des Données**



<b>\$</b>	Frequency \$	Rising \$	Review_average \$
count	96096.000000	96095.000000	95380.000000
mean	1.034809	166.594226	4.084989
std	0.214384	231.428912	1.341571
min	1.000000	0.000000	1.000000
25%	1.000000	63.120000	4.000000
50%	1.000000	108.000000	5.000000
75%	1.000000	183.530000	5.000000
max	17.000000	13664.080000	5.000000



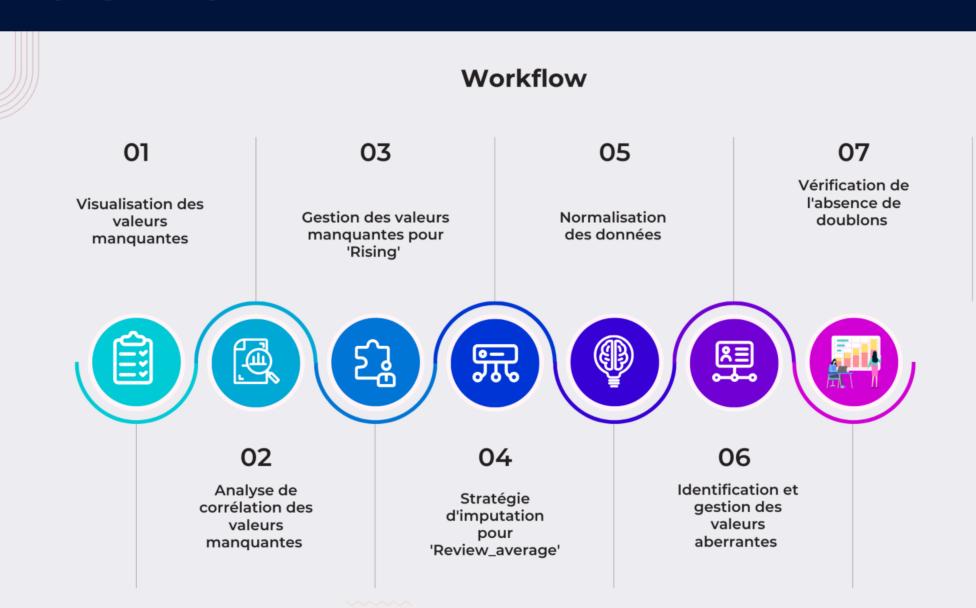
<b>\$</b>	Variable <b>♦</b>	Shapiro-Wilk <b>♦</b>	Kolmogorov-Smirnov \$	Anderson-Darling \$	D'Agostino-Pearson \$
0	Review_average	False	False	False	False
1	Rising	False	False	False	False
2	Frequency	False	False	False	False
3	Recency	False	False	False	False

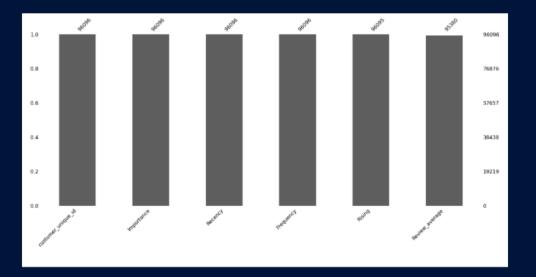






# Nettoyage du jeu de données

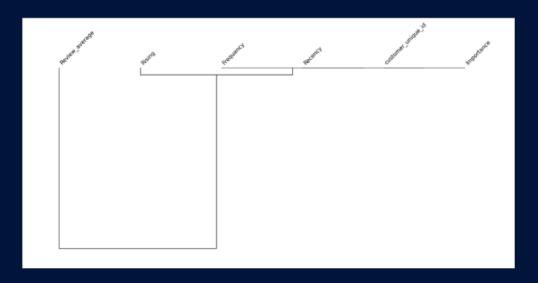




<b>\$</b>	Missing Values \$	Percentage \$
customer_unique_id	0	0.000000
Importance	0	0.000000
Recency	0	0.000000
Frequency	0	0.000000
Rising	1	0.001041
Review_average	716	0.745088

ф	Variable ≑	Nom du test ¢	Statistique de test ¢	p-valeur ¢	Normalité ¢
0	Review_average	Shapiro-Wilk	0.691650	0.000	Non
1	Review_average	Kolmogorov-Smirnov	0.863798	0.000	Non
2	Review_average	Anderson-Darling	12118.263484	NaN	Non
3	Review_average	D'Agostino-Pearson	18164.113444	0.000	Non
4	Review_average	Lilliefors	0.324883	0.001	Non

Valeurs manquantes après nettoyage :
customer\_unique\_id 0
Importance 0
Recency 0
Frequency 0
Rising 0
Review\_average 0
dtype: int64



```
Valeurs aberrantes détectées par variable :
                   customer_unique_id  
Importance  
Recency  
Frequency  
Rising  
Review_average  
Review_average  
    o 00053a61a98854899e70ed204dd4bafe
                                                                          1 419.18
                                               False
                                                            231
                                                                                              0.000000
     1 0005ef4cd20d2893f0d9fbd94d3c0d97
                                               False
                                                           219
                                                                          1 129.76
                                                                                              0.000000
     2 000de6019bb59f34c099a907c151d855
                                               False
                                                            425
                                                                          1 257.44
                                                                                              0.250000
     3 0010a452c6d13139e50b57f19f52e04e
                                                            463
                                                                          1 325.93
                                                                                              0.000000
                                               False
                                                            365
                                                                          1 155.65
     4 0012929d977a8d7280bb277c1e5f589d
                                               False
                                                                                              0.000000
         ff922bdd6bafcdf99cb90d7f39cea5b3
                                                True
                                                            398
                                                                          3 139.60
                                                                                              0.833333
 24517 ffe254cc039740e17dd15a5305035928
                                                            563
                                                                               80.12
                                                                                              0.500000
 24518 009b0127b727ab0ba422f6d9604487c7
                                               False
                                                            764
                                                                          1 40.95
                                                                                              0.000000
        4854e9b3feff728c13ee5fc7d1547e92
                                                           772
                                                                              75.06
                                                                                              0.000000
 24520 b7d76e111c89f7ebf14761390f0f7d17
                                               False
                                                           772
                                                                          1 136.23
                                                                                              0.000000
```

```
duplicates = df_data_clean[df_data_clean.duplicated()]

if len(duplicates) > 0:
    print("Notre jeu de données contient", len(duplicates), "doublon(s).")

else:
    print("Notre jeu de données ne contient pas de doublons.")

Notre jeu de données ne contient pas de doublons.
```





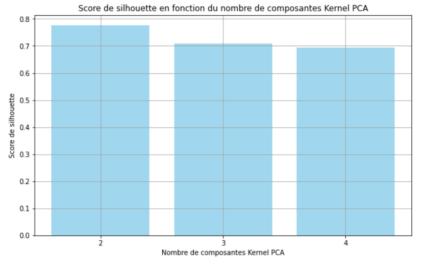
# **Modélisation**



<b>\$</b>	Normalisation \$	Silhouette Score \$	Davies-Bouldin Index \$	Temps de Calcul \$
0	Min-Max	0.459039	0.772232	194.893888
1	Standard	0.412250	0.964251	204.038569
2	Robust	0.502429	0.779281	203.990261

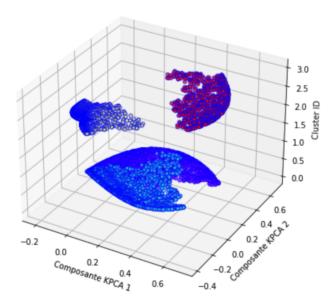
PCA Silhouette Score: 0.5622015328624331 Kernel PCA Silhouette Score: 0.7577758512305083 Isomap Silhouette Score: 0.6683052201065294 LLE Silhouette Score: 0.7407969080223582 t-SNE Silhouette Score: 0.3652634024620056

La méthode recommandée est : Kernel PCA avec un score de silhouette de 0.76

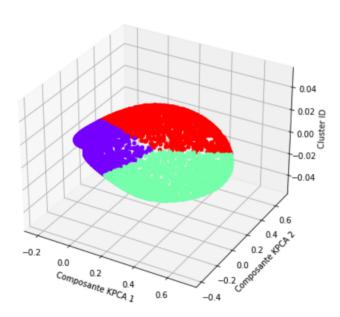


Meilleur score de silhouette: 0.78 Nombre de composantes Kernel PCA optimal: 2



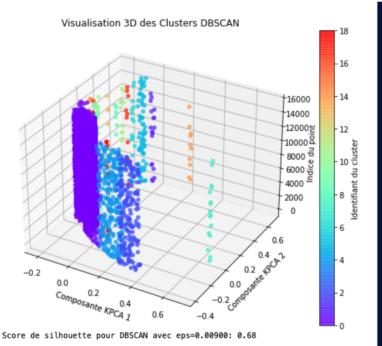


Score de silhouette pour les clusters hiérarchiques : 0.76



Vue "3D" des Clusters K-Means avec 3 clusters

Score de silhouette pour K-Means avec 3 clusters: 0.78







# Maintenance du Modèle

### Workflow

Requêtes à la Base de Données pour Diverses Périodes Temporelles

03

Nettoyage des

Données

05

Échantillonnage

des Données

07

Réduction Dimensionnelle 09

Calcul de l'Ajusted Rank Index (ARI)





















02

Calcul de la Recency, Frequency, et Monetary (RFM) pour Chaque Période 04

Normalisation

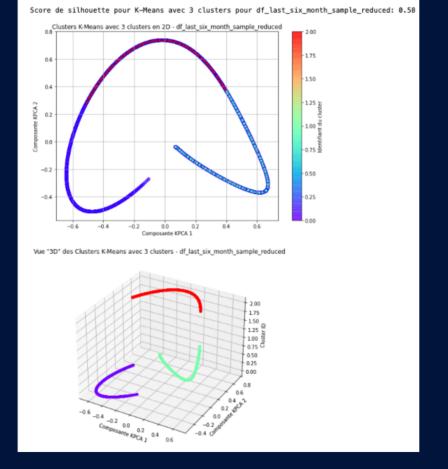
06

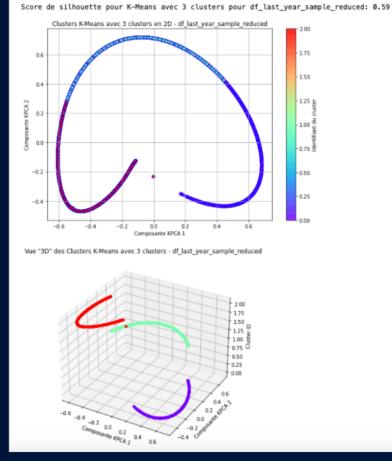
Encoding des Variables Catégorielles 80

Simulation de Clustering sur Différentes Périodes 10

Analyse de la Stabilité des Clusters et Recommandation sur la Fréquence de Mises à Jour

Score de silhouette pour K-Means avec 3 clusters pour df\_last\_month\_sample\_reduced: 0.66 Clusters K-Means avec 3 clusters en 2D - df\_last\_month\_sample\_reduced 1.50 -1.25 ₺ -100 0.0 -0.2 -0.50 -0.25 -0.4 0.0 Composante KPCA 1 Vue "3D" des Clusters K-Means avec 3 clusters - df\_last\_month\_sample\_reduced 1.00 0.50 -0.6 <sub>-0.4</sub> <sub>-0.2</sub> 0.0 0.2





ARI entre le dernier mois et les six derniers mois: 0.012827942779790618
ARI entre le dernier mois et l'année dernière: -0.019316097283613005
ARI entre les six derniers mois et l'année dernière: -0.001969560502945367

#